

# 胡婕

电话: 182-0013-9789 邮箱: hujie@stu.pku.edu.cn

## 教育背景

|                           |                   |
|---------------------------|-------------------|
| 北京大学                      | 北京                |
| 数据科学专业博士                  | 2023.09 – 至今      |
| 同济大学                      | 上海                |
| 数学与应用数学专业本科 GPA: 4.74/5.0 | 2019.09 – 2023.06 |

## 研究兴趣

主要关注机器学习算法和系统的高效性, 通过优化模型架构, 包括压缩和稀疏化等技术, 实现更优的精度-效率平衡, 包括大语言模型、多模态大模型等。

## 论文发表

- **Distributed Bilevel Optimization with Communication Compression**  
*Yutong He\*, Jie Hu\*, Xinmeng Huang, Songtao Lu, Bin Wang, Kun Yuan*  
International Conference on Machine Learning (ICML) 2024.
- **CentroidKV: Efficient Long-Context LLM Inference via KV Cache Clustering**  
*Jie Hu\*, Shengnan Wang\*, Yutong He, Ping Gong, Jiawei Yi, Juncheng Zhang, Youhui Bai, Renhai Chen, Gong Zhang, Cheng Li, Kun Yuan*  
Arxiv, 2025.
- **DFSAttn: Dynamic Fine-grained Sparse Attention for Efficient Video Generation**  
*Jie Hu, Zixiang Gao, Yutong He, Kun Yuan*  
International Conference on Machine Learning (ICML) 2026.

## 实习经历

|                                                        |                   |
|--------------------------------------------------------|-------------------|
| 华为 2012 实验室                                            | 北京                |
| 职位: 研究实习生                                              | 2024.08 – 2025.07 |
| • 研究长上下文 LLM 推理中的 KV Cache 瓶颈, 提出在线 KV Cache 聚类框架      |                   |
| • 实现低开销分块聚类与 KV 合并, 保持模型性能并降低显存开销, 解码加速 1.92×, 吞吐提升 4× |                   |

## 荣誉奖项

- 北京大学三好学生 2024
- 北京大学兴业奖学金 2024
- 同济大学优秀学生, 一等奖学金 2021, 2022

## 技术能力

- 编程与工具: Python, Git, L<sup>A</sup>T<sub>E</sub>X
- 深度学习框架: PyTorch, Transformers